

Ayudantía 02: Machine Learning

Profesor: Dr. Juan Bekios Calfa

Ayudante: Sr. Gael Ortega Cortés

Tema: Comprensión y preparación de datos (Data Understanding)

Duración: 60 minutos

1. (10 points) **CRISP-DM y fases de datos** Responda brevemente:

(a) ¿En qué fase se detectan los datos faltantes y outliers?

(b) ¿En qué fase se seleccionan los algoritmos de clasificación o regresión?

(c) ¿Por qué es importante que el modelo cumpla con los objetivos del negocio y no solo con métricas técnicas?

2. (10 points) **Exploración de un CSV con Pandas** Dado el siguiente código:

```
import pandas as pd

df = pd.read_csv("dataset.csv")
print(df.head())
df.info()
print(df.describe())
```

(a) Explique qué hace cada línea del código.

(b) ¿En qué salida se pueden detectar valores faltantes?

(c) ¿Qué utilidad tiene `describe()` en la comprensión de los datos?

3. (10 points) **Obtención de datos desde la web** Dado el siguiente código:

```
import requests
response = requests.get("https://www.google.com")
print(response.status_code)
print(response.headers["Content-Type"])
```

(a) ¿Qué significa que el código de estado HTTP sea 200?

(b) ¿Cómo se podría obtener el contenido textual de la página?

(c) ¿Qué diferencia existe entre `response.text` y `response.content`?

4. (10 points) **Procesamiento de HTML con BeautifulSoup** Dado el siguiente HTML y código en Python:

```
from bs4 import BeautifulSoup
html = """<table>
<tr><th>Nombre</th><th>Edad</th></tr>
<tr><td>Ana</td><td>20</td></tr>
<tr><td>Pedro</td><td>25</td></tr>
</table>"""
soup = BeautifulSoup(html, "html.parser")
rows = soup.find_all("tr")
for row in rows:
    print([cell.text for cell in row.find_all(["th", "td"])])
```

(a) Explique cómo se extraen los datos de la tabla.

(b) Modifique el código para crear un DataFrame con los datos.

5. (10 points) **Expresiones regulares** Dada la siguiente cadena:

```
texto = "cnm_lr0.01_bs32_opAdam_freTrue_taugFlip_20240903_1530.csv"
```

(a) Construya una expresión regular que extraiga modelo, learning rate, batch size y optimizador.

(b) Guarde los datos extraídos en un diccionario de Python.

6. (10 points) **Método Filter: selección de características mediante χ^2** El método *Filter* permite seleccionar atributos antes de entrenar un modelo. Cuando el atributo y la variable objetivo son categóricos, se puede utilizar la prueba de independencia χ^2 para medir si existe asociación entre ambas variables.

Se evaluarán tres atributos:

X_1 = Tiene experiencia, X_2 = Tiene certificación, X_3 = Trabaja remotamente.

La variable objetivo es:

$$Y = \begin{cases} 1 & \text{Contratado,} \\ 0 & \text{No contratado.} \end{cases}$$

¿Qué es una tabla de contingencia?

Una tabla de contingencia resume las **frecuencias observadas** para cada combinación de dos variables categóricas.

- Las **filas** representan las categorías del atributo: Sí o No.
- Las **columnas** representan las categorías de la variable objetivo: contratado ($Y = 1$) o no contratado ($Y = 0$).
- Las celdas interiores contienen las **frecuencias observadas**.
- La última columna contiene los **totales por fila**.
- La última fila contiene los **totales por columna**.
- Los totales por fila y columna también se denominan **frecuencias marginales**.

Tabla de contingencia para X_1 : Tiene experiencia

X_1 : Tiene experiencia	Variable objetivo Y		Total
Categoría	Contratado ($Y = 1$)	No contratado ($Y = 0$)	Fila
Sí	30	10	40
No	10	30	40
Total columna	40	40	80

Esta tabla indica, por ejemplo, que:

- 30 personas **tienen experiencia y fueron contratadas**.
- 10 personas **tienen experiencia y no fueron contratadas**.
- 10 personas **no tienen experiencia y fueron contratadas**.
- 30 personas **no tienen experiencia y no fueron contratadas**.
- En total existen 40 personas contratadas y 40 no contratadas.
- El conjunto contiene un total de 80 observaciones.

Tabla de contingencia para X_2 : Tiene certificación

X_2 : Tiene certificación	Variable objetivo Y		Total
Categoría	Contratado ($Y = 1$)	No contratado ($Y = 0$)	Fila
Sí	25	15	40
No	15	25	40
Total columna	40	40	80

Tabla de contingencia para X_3 : Trabaja remotamente

X_3 : Trabaja remotamente	Variable objetivo Y		Total
Categoría	Contratado ($Y = 1$)	No contratado ($Y = 0$)	Fila
Sí	21	19	40
No	19	21	40
Total columna	40	40	80

Para calcular χ^2 , primero se debe determinar la **frecuencia esperada** de cada celda suponiendo que el atributo y la variable objetivo son independientes.

$$E_{ij} = \frac{(\text{total fila}_i)(\text{total columna}_j)}{\text{total general}}.$$

Por ejemplo, para $X_1 = \text{Sí}$ tiene experiencia y $Y = 1$:

$$E = \frac{40 \cdot 40}{80} = 20.$$

Esto significa que, si tener experiencia y ser contratado fueran independientes, se esperarían 20 personas en esa celda. Sin embargo, se observaron 30, por lo tanto:

$$O = 30, \quad E = 20.$$

Una vez calculadas las frecuencias esperadas:

$$\chi^2 = \sum_i \frac{(O_i - E_i)^2}{E_i}.$$

donde O_i es la frecuencia observada y E_i la frecuencia esperada.

(a) Calcule las cuatro frecuencias esperadas para X_1 .

(b) Complete la siguiente tabla para X_1 .

Combinación	Observado O_i	Esperado E_i
Sí experiencia / $Y = 1$	30	
Sí experiencia / $Y = 0$	10	
No experiencia / $Y = 1$	10	
No experiencia / $Y = 0$	30	

(c) Calcule el valor de χ^2 para X_1 .

(d) Calcule el valor de χ^2 para X_2 .

(e) Calcule el valor de χ^2 para X_3 .

(f) Complete la siguiente tabla resumen.

Atributo	Valor de χ^2
X_1 : Tiene experiencia	
X_2 : Tiene certificación	
X_3 : Trabaja remotamente	

(g) Ordene los atributos desde el más relacionado hasta el menos relacionado con Y .

>	>
---	---

(h) ¿Qué atributo seleccionaría primero un método Filter basado en χ^2 ? Justifique su

respuesta.

7. (10 points) **Método Filter: selección de características mediante correlación de Pearson** Cuando los atributos y la variable objetivo son numéricos, una alternativa es utilizar el coeficiente de correlación de Pearson.

Observación	X_1	X_2	X_3	Y
1	1	5	2	2
2	2	4	5	4
3	3	3	1	6
4	4	2	4	8
5	5	1	3	10

El coeficiente de correlación de Pearson se calcula como:

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}.$$

Su rango es $-1 \leq r \leq 1$.

- r cercano a 1: relación lineal positiva fuerte.
- r cercano a -1 : relación lineal negativa fuerte.
- r cercano a 0: relación lineal débil o inexistente.

En selección de características suele utilizarse $|r|$ porque tanto una relación positiva fuerte como una negativa fuerte indican una asociación importante con la variable objetivo.

- (a) Calcule las medias de X_1 y Y .

$$\bar{X}_1 = \underline{\hspace{2cm}} \quad \bar{Y} = \underline{\hspace{2cm}}$$

- (b) Calcule la correlación de Pearson entre X_1 e Y .

$$r_{X_1, Y}$$

(c) Calcule la correlación de Pearson entre X_2 e Y .

$$r_{X_2,Y}$$

(d) Calcule la correlación de Pearson entre X_3 e Y .

$$r_{X_3,Y}$$

(e) Complete la siguiente tabla.

Atributo	Correlación con Y	$ r $
X_1		
X_2		
X_3		

(f) Ordene los atributos de mayor a menor relevancia utilizando $|r|$.

>
>

(g) Explique por qué se utiliza $|r|$ y no solamente r para ordenar los atributos.

8. (10 points) **Desafío final: Mini-pipeline de comprensión de datos** Implemente un pequeño pipeline en Python que:

1. Cargue un archivo CSV utilizando Pandas.
2. Detecte los valores faltantes.
3. Identifique las tres columnas numéricas con mayor correlación, en valor absoluto, con la variable `target`.

4. Muestre un histograma o boxplot de una de esas variables.
