

Pauta comentada: Ayudantía 03

Machine Learning | Dr. Juan Bekios Calfa | Gael Ortega Cortés

Objetivo. Esta pauta incluye cada enunciado y su solución explicada. Se desarrollan los criterios, los cálculos y la interpretación para que pueda usarse como material de estudio y repaso para la Prueba 1. Intente resolver cada ejercicio antes de consultar su solución y compare el procedimiento con su respuesta. En las operaciones se conservan los valores sin redondear hasta el final.

Ejercicios

1. (IA y paradigmas de aprendizaje)

- Compare búsqueda, sistemas basados en conocimiento y aprendizaje automático según el conocimiento explícito aportado por expertos y la dependencia de datos. ¿Por qué un agente inteligente puede combinar estos enfoques?
- Clasifique los casos: detectar spam con correos etiquetados; predecir consumo eléctrico en kWh; agrupar noticias sin etiquetas; reducir variables correlacionadas sin etiquetas; aprender a mover un robot mediante recompensas.
- Distinga un modelo discriminativo que estima $P(Y | X)$ de uno generativo que modela $P(X)$ o $P(X, Y)$. Dé un ejemplo de uso de cada uno.

Resultado. (a) Búsqueda: explorar acciones; sistema de conocimiento: aplicar reglas; ML: aprender de datos. Un agente puede combinar los tres. (b) Spam: clasificación supervisada; kWh: regresión supervisada; noticias: clustering no supervisado; reducción de variables: PCA/no supervisado; robot con recompensas: refuerzo. (c) Discriminativo: $P(Y | X)$, por ejemplo regresión logística; generativo: $P(X)$ o $P(X, Y)$, por ejemplo Naive Bayes.

Cómo se obtiene. En búsqueda se diseñan estados, acciones y meta; en un sistema de conocimiento, hechos y reglas; en ML, ejemplos y objetivo para ajustar parámetros. Las etiquetas distinguen clasificación y regresión supervisadas de clustering y PCA. El refuerzo aprende de recompensas. Un modelo discriminativo parte de X para decidir Y ; uno generativo modela cómo se distribuyen los datos.

2. (CRISP-DM aplicado a un proyecto) Un equipo quiere analizar noticias para apoyar a un analista.

- Asigne a la fase pertinente: definir el problema y criterio de éxito; explorar distribuciones y correlaciones; imputar faltantes; entrenar un modelo; evaluar sus errores; publicar una API para usarlo.
- Después de evaluar, el equipo detecta que faltan datos de una fuente importante. ¿A qué fase regresaría *primero* para obtener y examinar esos datos? Explique por qué CRISP-DM permite volver a una fase anterior.

Resultado. (a) Problema y éxito: Business Understanding; distribuciones y correlaciones: Data Understanding; imputación: Data Preparation; entrenamiento: Modeling; errores: Evaluation; API: Deployment. (b) Volver primero a Data Understanding.

Cómo se obtiene. Explorar describe y detecta problemas; imputar ya modifica los datos. La fuente faltante debe obtenerse y examinarse antes de preparar, modelar y evaluar de nuevo. CRISP-DM permite regresar a fases anteriores cuando la evaluación revela una carencia.

3. (Métodos HTTP y APIs REST) Suponga que trabaja con el recurso:

<https://api.ejemplo.com/usuarios/15>

- (a) Indique qué método HTTP usaría para consultar el usuario 15.
- (b) Indique qué método HTTP usaría para reemplazar completamente los datos del usuario 15.
- (c) Indique qué método HTTP usaría para eliminar el usuario 15.

Resultado. (a) GET. (b) PUT. (c) DELETE.

Cómo se obtiene. La URL identifica al usuario 15. GET consulta ese recurso, PUT reemplaza completamente sus datos y DELETE solicita eliminarlo.

4. **(Expresiones Regulares: Agrupaciones y Matching Perezoso)** Considere el siguiente código en Python:

```
import re
texto = "<item>valor1</item><item>valor2</item>"
patron = re.compile(r'<(\w+)>(.*?)</(\w+)>')
match = patron.search(texto)
```

- (a) Escriba la coincidencia completa encontrada por `match.group(0)`.
- (b) Escriba el contenido de `match.group(1)`.
- (c) Escriba el contenido de `match.group(2)`.
- (d) Escriba el contenido de `match.group(3)`.

Resultado. (a) `group(0)`: `<item>valor1</item>`. (b) `group(1)`: `item`. (c) `group(2)`: `valor1`. (d) `group(3)`: `item`.

Cómo se obtiene. `search` toma la primera coincidencia completa. Los paréntesis numeran las tres capturas de izquierda a derecha: apertura, contenido y cierre. El `.*` es perezoso, por lo que se detiene en el primer cierre que permite completar el patrón.

5. **(HTML y BeautifulSoup)** Considere el siguiente fragmento de código HTML:

```
<table>
<tr><th>Nombre</th><th>Edad</th></tr>
<tr><td>Ana</td><td>20</td></tr>
<tr><td>Carlos</td><td>22</td></tr>
</table>
```

- (a) ¿Cuántas columnas tiene la tabla?
- (b) Escriba los nombres de los encabezados extraídos.
- (c) Escriba la segunda fila de datos representada como una lista de Python.

Resultado. (a) 2 columnas. (b) `['Nombre', 'Edad']`. (c) `['Carlos', '22']`.

Cómo se obtiene. La primera fila contiene dos etiquetas `<th>`; se omite al contar filas de datos. Carlos ocupa la segunda fila de `<td>`. BeautifulSoup extrae texto, así que `'22'` es una cadena, no el entero 22.

6. **(Clasificación de Tipos de Datos)** Considere las siguientes tres variables recolectadas en un estudio:

A = tipo de mascota, B = nivel de satisfacción: [bajo, medio, alto], C = temperatura en grados Celsius

- (a) Clasifique A según su escala de medición (nominal, ordinal, intervalo o razón).
- (b) Clasifique B según su escala de medición.
- (c) Clasifique C según su escala de medición. Justifique brevemente el cero en esta escala.

Resultado. (a) A : nominal. (b) B : ordinal. (c) C : intervalo.

Cómo se obtiene. Las mascotas son categorías sin orden; bajo, medio y alto sí tienen orden. En Celsius importan las diferencias, pero 0°C no significa ausencia de temperatura: 20°C no es el doble de 10°C .

7. **(Procesamiento de Matrices e Histograma)** Se tiene la siguiente matriz de intensidades de una subimagen:

$$\begin{bmatrix} 10 & 50 & 200 \\ 10 & 80 & 200 \\ 20 & 80 & 150 \end{bmatrix}$$

- (a) ¿Cuántos valores totales se obtienen al aplanar (*flatten*) la matriz?
- (b) ¿Cuál es la frecuencia observada del valor 80?
- (c) ¿Qué tipo de gráfico es el más adecuado para estudiar la distribución de frecuencias de estos valores? Justifique.

Resultado. (a) 9 valores. (b) El 80 aparece 2 veces. (c) Histograma de intensidades.

Cómo se obtiene. Aplanar convierte las 3×3 celdas en una secuencia: $[10, 50, 200, 10, 80, 200, 20, 80, 150]$. El 80 está en las filas segunda y tercera. Un histograma muestra frecuencias por intervalos numéricos; para comparar solo valores exactos también servirían barras.

8. **(Visualización con Matplotlib)** Considere el siguiente bloque de código:

```
import matplotlib.pyplot as plt
categorias = ['A', 'B', 'C']
valores = [5, 8, 3]
plt.bar(categorias, valores)
# línea faltante
plt.show()
```

- (a) Escriba la instrucción exacta faltante para agregar un título con el texto 'Frecuencia por categoría'.
- (b) Justifique por qué un gráfico de barras es apropiado para representar estas variables en lugar de un gráfico de líneas continuas.

Resultado. (a) `plt.title('Frecuencia por categoría')`. (b) Gráfico de barras.

Cómo se obtiene. La instrucción se coloca antes de `plt.show()`. A, B y C son categorías separadas; las alturas 5, 8 y 3 se comparan sin sugerir valores continuos entre ellas, como haría una línea.

9. **(Selección y Diseño de Visualizaciones)** Un equipo de ciencia de datos tiene dos variables numéricas continuas x e y , y desea estudiar si existe una relación no lineal entre ambas. Adicionalmente, cuenta con una tercera variable categórica con dos grupos (Clase A y Clase B).

- (a) Indique qué tipo de gráfico usaría para analizar la relación entre x e y .
- (b) ¿Cómo podría representarse visualmente la tercera variable categórica en el mismo plano bidimensional?

- (c) Explique por qué un gráfico de torta (*pie chart*) no es adecuado para cumplir este propósito.

Resultado. (a) Gráfico de dispersión. (b) Color o marcador distinto para cada clase, con leyenda. (c) No usar gráfico de torta.

Cómo se obtiene. Cada observación conserva su par (x_i, y_i) en el plano; así puede verse una tendencia curva. El color añade la clase sin perder los pares. La torta muestra proporciones de categorías, no relaciones entre dos variables numéricas.

Antes del ejercicio 10: imputación. Imputar es estimar un dato faltante para poder trabajar con la tabla; no recupera el valor verdadero. Con n valores observados, sin contar NaN, la media es $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$. La mediana es el valor central tras ordenar; si n es par, se promedian los dos centrales. Un valor extremo puede desplazar la media mucho más que la mediana.

10. (**Comparación de estrategias de imputación**) En un conjunto de sueldos observados se tiene

$$S = [1000, 1100, 1200, 3000, 3200, 20000, \text{NaN}].$$

- (a) Calcule el valor que usaría para imputar el faltante con la media y con la mediana de los valores observados.
 (b) Elija una estrategia para estos datos y justifique la influencia del valor 20000.
 (c) Explique en qué consiste imputar mediante un modelo predictivo y por qué no sería razonable entrenarlo solo con los seis sueldos observados aquí.

Resultado. (a) Media = $\boxed{4916,67}$; mediana = $\boxed{2100}$. (b) Elegir la mediana en este ejemplo. (c) No entrenar un imputador predictivo con estos seis sueldos aislados.

Cómo se obtiene. Se excluye NaN: la suma de los seis observados es 29500, luego $\bar{x} = 29500/6 \approx 4916,67$. Los valores centrales ordenados son 1200 y 3000, luego la mediana es $(1200 + 3000)/2 = 2100$. El 20000 eleva la media, aunque puede ser legítimo. Un modelo predictivo necesitaría otras variables explicativas y muchos más registros completos para aprender y evaluarse.

Antes del ejercicio 11: Min-Max. Sirve para llevar los valores de una característica al intervalo $[0, 1]$ sin alterar su orden. Con mínimo $x_{\min}$ y máximo $x_{\max}$ calculados en los datos de referencia, se usa $x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$. El mínimo pasa a 0 y el máximo a 1; se requiere $x_{\max} \neq x_{\min}$.

11. (**Escalado de Datos: Min-Max**) Considere una característica numérica con las siguientes observaciones:

$$X = [10, 20, 30, 40]$$

- (a) Identifique el valor mínimo ($x_{\min}$) y máximo ($x_{\max}$) de la muestra.
 (b) Calcule paso a paso el valor normalizado para $x = 30$ utilizando la fórmula de Min-Max al rango $[0, 1]$.
 (c) Indique cuál es el rango numérico resultante habitual de esta transformación.

Resultado. (a) $x_{\min} = 10$, $x_{\max} = 40$. (b) $x' = \boxed{2/3 \approx 0,667}$. (c) Rango $[0, 1]$ para los datos de referencia.

Cómo se obtiene. Sustituir en Min-Max: $x' = (30 - 10)/(40 - 10) = 20/30 = 2/3$. El resultado sitúa 30 a dos tercios entre el mínimo y el máximo; no es una probabilidad. Un dato futuro fuera del rango original podría quedar fuera de $[0, 1]$.

Antes del ejercicio 12: estandarización. StandardScaler compara un valor con el centro y la dispersión de su característica. Con N observaciones, $\mu = \frac{1}{N} \sum_{i=1}^N x_i$, $\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$ y $z = \frac{x - \mu}{\sigma}$ (se requiere $\sigma > 0$). El puntaje z indica cuántas desviaciones estándar separan x de la media: $z = 0$ en la media, positivo por encima y negativo por debajo; no es una probabilidad ni queda limitado a $[0, 1]$. Para comparar, Min-Max en $[0, 1]$ usa $x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$.

12. (Min-Max frente a StandardScaler) Sea

$$X = [10, 20, 30, 40, 100].$$

- Calcule la media y la desviación estándar de X usando divisor N .
- Transforme $x = 30$ con Min-Max al intervalo $[0, 1]$ y con StandardScaler. Muestre ambos procedimientos.
- Explique por qué un algoritmo basado en distancias suele ser sensible a la escala y por qué un árbol de decisión es, en general, menos sensible.

Resultado. (a) $\mu = 40$, $\sigma = \sqrt{1000} \approx 31,623$. (b) Min-Max: $2/9 \approx 0,222$; StandardScaler: $-1/\sqrt{10} \approx -0,316$. (c) Las distancias suelen cambiar con la escala; los árboles suelen ser menos sensibles.

Cómo se obtiene. La suma es 200 y $N = 5$, así que $\mu = 40$. Las desviaciones cuadradas suman $900 + 400 + 100 + 0 + 3600 = 5000$; $\sigma = \sqrt{5000/5} = \sqrt{1000}$. Min-Max usa extremos 10 y 100: $(30 - 10)/(100 - 10) = 2/9$. El puntaje $z = (30 - 40)/\sqrt{1000} \approx -0,316$ indica 0,316 desviaciones bajo la media. En KNN una variable de gran escala puede dominar la distancia; un árbol divide por umbrales y conserva el orden bajo escalados monótonos.

Antes del ejercicio 13: escalado robusto. Q_1 y Q_3 delimitan la mitad central de los datos; su distancia es $IQR = Q_3 - Q_1$. RobustScaler centra en la mediana y transforma mediante $x' = \frac{x - \text{mediana}(X)}{Q_3 - Q_1}$, siempre que $IQR > 0$. La mediana y el IQR suelen cambiar menos que la media, la desviación estándar o los extremos cuando hay valores atípicos. El resultado no queda restringido a un intervalo fijo.

13. (Escalado Robusto: RobustScaler) En un proceso industrial con valores atípicos se obtienen:

$$\text{mediana} = 50, \quad Q_1 = 40, \quad Q_3 = 70$$

- Calcule el rango intercuartílico (IQR).
- Calcule el valor transformado de $x = 65$ aplicando *RobustScaler*.
- ¿Por qué este método de escalado es más conveniente que *StandardScaler* cuando los datos presentan outliers severos?

Resultado. (a) $IQR = 30$. (b) Valor transformado = $0,5$. (c) Menor influencia de valores extremos.

Cómo se obtiene. $IQR = Q_3 - Q_1 = 70 - 40 = 30$; RobustScaler da $(65 - 50)/30 = 0,5$. La mediana y los cuartiles dependen de la zona central y cambian menos que media y desviación estándar ante outliers. No eliminan los outliers ni fijan un rango de salida.

14. (Tratamiento de Valores Faltantes en Pandas) Considere el siguiente fragmento de código:

```
import pandas as pd
df = pd.DataFrame({'edad': [20, None, 30, 40]})
media = df['edad'].mean()
# línea faltante
```

- (a) Escriba la línea de código en Pandas requerida para imputar los valores faltantes de la columna `edad` utilizando la variable `media`.
- (b) Calcule manualmente el valor numérico exacto de la media imputada.

Resultado. (a) `df['edad'] = df['edad'].fillna(media)`. (b) `media= 30`.

Cómo se obtiene. Pandas omite `None` en `mean()`: $(20 + 30 + 40)/3 = 30$. `fillna(media)` devuelve la columna con el faltante sustituido; la asignación la guarda en `df`. Queda `[20, 30, 30, 40]`.

Antes del ejercicio 15: categorías. Una variable nominal contiene categorías sin orden. One-Hot Encoding sustituye esa columna por un indicador binario para cada categoría: el indicador vale 1 cuando la observación pertenece a ella y 0 en otro caso. Label Encoding, en cambio, asigna números enteros a los nombres de las categorías; esos números pueden introducir un orden artificial.

15. **(Codificación de Variables Categóricas)** Se tiene un atributo de equipos de trabajo:

`team = [A, B, C, A]`

- (a) ¿Cuántas columnas nuevas genera One-Hot Encoding?
- (b) Escriba la representación codificada del primer registro (`A`).
- (c) Explique por qué Label Encoding podría ser problemático si la variable es nominal.

Resultado. (a) 3 columnas. (b) Primer A: `[1, 0, 0]`. (c) Label Encoding puede imponer orden y distancias artificiales.

Cómo se obtiene. Hay tres categorías, luego se crean `team_A`, `team_B` y `team_C`. En ese orden, A activa solo la primera. Asignar A= 0, B= 1, C= 2 haría parecer que C es mayor que B y que A-C está al doble de distancia que A-B, aunque los equipos no tienen ese orden.

Antes del ejercicio 16: umbral de varianza. La varianza mide dispersión alrededor de la media: $\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$ y $\text{Var}(X) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$. Un umbral t es un valor de corte: el filtro conserva las características con $\text{Var}(X_j) > t$ y elimina las demás. Solo examina la variación de cada columna, sin mirar la clase que se quiere predecir.

16. **(Selección de Características: Umbral de Varianza)** Tres características continuas presentan las siguientes varianzas:

$$\text{Var}(X_1) = 0,02, \quad \text{Var}(X_2) = 0,40, \quad \text{Var}(X_3) = 0,15$$

El criterio de corte define un umbral de varianza mínimo exigido de 0,10.

- (a) ¿Cuál característica es eliminada por el filtro?
- (b) ¿Cuáles características son conservadas?
- (c) ¿Por qué una variable casi constante suele aportar poca información? Explique por qué esto no garantiza que sea irrelevante para predecir la clase.

Resultado. (a) Eliminar `X1`. (b) Conservar `X2, X3`. (c) Poca variación no prueba irrelevancia predictiva.

Cómo se obtiene. Comparar con 0,10: 0,02 < 0,10; 0,40 y 0,15 lo superan. Una columna casi constante distingue pocos casos, pero podría identificar una clase rara. El filtro no mira la clase y la varianza también depende de la escala de cada característica.

Antes del ejercicio 17: Pearson. Sirve para medir dirección y fuerza de la asociación *lineal* entre pares numéricos (x_i, y_i) . Con sus medias $\bar{x}$ y $\bar{y}$:

$$r_{XY} = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^N (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^N (y_i - \bar{y})^2}}.$$

Está entre -1 y 1 ; el signo indica dirección y $|r|$ cercano a 1 , relación lineal fuerte. Un valor cercano a cero no descarta una curva.

17. **(Correlación Lineal de Pearson)** Se analizan horas de estudio (X) y calificación (Y):

$$X = [2, 4, 6, 8, 10], \quad Y = [50, 55, 65, 70, 80]$$

Se sabe previamente que los promedios son $\bar{X} = 6$ y $\bar{Y} = 64$.

- (a) Indique el signo y sentido de la relación lineal entre ambas variables.
- (b) De los siguientes tres valores, seleccione el coeficiente de correlación $r_{X,Y}$ más coherente:

$$0,99, \quad -0,99, \quad 0,00$$

- (c) Interprete el significado práctico del valor seleccionado en el contexto del rendimiento académico.
- (d) Calcule $r_{X,Y}$ con la fórmula de Pearson y compare el resultado con el valor que seleccionó.

Resultado. (a) Positiva. (b) 0,99. (c) Asociación lineal positiva muy fuerte. (d) $r = \boxed{0,9934}$.

Cómo se obtiene. Con $\bar{X} = 6$ y $\bar{Y} = 64$, las desviaciones son $[-4, -2, 0, 2, 4]$ y $[-14, -9, 1, 6, 16]$. La suma de productos es 150 y las sumas de cuadrados son 40 y 570. Así, $r = 150/\sqrt{40 \cdot 570} \approx 0,9934$, que redondea a 0,99. Correlación no demuestra causalidad.

Antes del ejercicio 18: chi-cuadrado. Una tabla de contingencia cruza dos variables categóricas. O_{ij} es el conteo observado en la celda de fila i y columna j . Bajo la idea de independencia, el conteo esperado es $E_{ij} = \frac{(\text{total de fila } i)(\text{total de columna } j)}{N}$, con N casos en total. Si hay r filas y c columnas, la discrepancia total se calcula con $\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$. Cuanto mayor sea, más difieren observado y esperado.

18. **(Independencia y estadístico chi-cuadrado)** Para el atributo *Color* de un hongo y la clase *Comestible*, se obtuvo esta tabla de frecuencias observadas:

Color	Comestible: Sí	Comestible: No	Total Fila
Rojo	20	5	25
Azul	3	17	20
Verde	10	10	20
Total Columna	33	32	65

- (a) Calcule la frecuencia esperada (E_{ij}) para la casilla (*Rojo*, *Sí*).
- (b) Calcule la frecuencia esperada (E_{ij}) para la casilla (*Rojo*, *No*).
- (c) En el marco de selección de características, ¿un valor elevado de χ^2 sugiere una alta o baja asociación entre la característica y la clase?
- (d) Calcule las demás frecuencias esperadas y el estadístico χ^2 total. Explique qué indica ese resultado acerca de la independencia entre Color y Comestible.

Resultado. (a) $E_{\text{Rojo,Sí}} = \boxed{12,6923}$. (b) $E_{\text{Rojo,No}} = \boxed{12,3077}$. (c) Un χ^2 alto sugiere mayor asociación. (d) $\chi^2 = \boxed{18,7891}$.

Cómo se obtiene. Cada esperado es $E = (\text{total fila})(\text{total columna})/65$. Para Rojo: $25 \cdot 33/65$ y $25 \cdot 32/65$; para Azul y Verde: $20 \cdot 33/65 \approx 10,1538$ y $20 \cdot 32/65 \approx 9,8462$ en cada fila. Los seis aportes $(O - E)^2/E$, en orden de lectura, son 4,2075, 4,3389, 5,0402, 5,1977, 0,0023 y 0,0024; su suma es 18,7891. Use los esperados sin redondear hasta el final. Las mayores diferencias están en Rojo y Azul.

Antes del ejercicio 19: seleccionar o extraer. RFE (eliminación recursiva de características) entrena un modelo, elimina la variable que este considera menos importante y vuelve a entrenar. En un modelo lineal, $\hat{y} = b + \sum_{j=1}^p w_j x_j$; el peso $w_j = 0$ significa que x_j no aporta directamente a esa predicción. Lasso minimiza $L(\mathbf{w}, b) + \alpha \sum_{j=1}^p |w_j|$: L es el error del modelo y $\alpha \geq 0$ controla la penalización L1, que puede llevar pesos a cero. PCA, en cambio, crea componentes nuevas como combinaciones de variables originales. Si λ_j es la varianza de la componente j , las primeras k retienen $V_k = \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^m \lambda_j}$ de la varianza total. PCA no utiliza la clase.

19. (Métodos de selección y extracción de características)

- Clasifique como filtro, envolvente o integrado: umbral de varianza, correlación de Pearson, eliminación recursiva RFE y selección por coeficientes nulos con Lasso. Compare brevemente la dependencia del modelo y el costo computacional.
- Distinga la selección de variables originales de la extracción de nuevas componentes mediante PCA.
- Si PCA entrega proporciones de varianza explicada

$$[0,72, 0,23, 0,05],$$

¿cuántos componentes bastan para retener al menos el 95 % de la varianza?

Resultado. (a) Filtros: varianza y Pearson (rápidos); envolvente: RFE (más costoso); integrado: Lasso (ligado al modelo). (b) Selección conserva variables originales; PCA crea componentes nuevas. (c) Bastan $\boxed{2}$ componentes.

Cómo se obtiene. Un filtro calcula una estadística sin entrenar el modelo final. RFE entrena, elimina la variable menos importante y vuelve a entrenar; por eso depende del modelo y suele costar más. Lasso selecciona durante el ajuste: su penalización L1 $\alpha \sum_j |w_j|$ puede hacer $w_j = 0$ si la mejora al mantener esa variable no compensa la penalización; ese peso ya no aporta a la predicción lineal. PCA transforma las variables en combinaciones lineales que captan varianza, sin usar la clase: $0,72 + 0,23 = 0,95$. Ese 95 % es varianza retenida, no exactitud de clasificación.

Ejercicios extra

Resuelva estos ejercicios para profundizar y practicar de forma autónoma.

T1. Intensidades de una imagen y elección de gráficos. Considere la matriz de intensidades

$$\begin{bmatrix} 10 & 50 & 50 & 200 \\ 10 & 80 & 80 & 200 \\ 20 & 80 & 150 & 150 \\ 20 & 100 & 150 & 200 \end{bmatrix}.$$

Aplane la matriz, calcule las frecuencias de 80 y 150, y construya una tabla de frecuencias. Compare un histograma de intensidades con un gráfico de barras de valores exactos: ¿qué pregunta responde mejor cada uno?

Resultado. Hay 16 valores; 80 aparece 3 veces y 150, 3 veces. Frecuencias: 10 : 2, 20 : 2, 50 : 2, 80 : 3, 100 : 1, 150 : 3, 200 : 3.

Cómo se obtiene. Aplanar por filas produce [10, 50, 50, 200, 10, 80, 80, 200, 20, 80, 150, 150, 20, 100, 150, 200]. Las frecuencias suman 16. Un histograma muestra concentración por intervalos numéricos; barras separadas comparan los siete valores exactos. **T2. Escalado adicional.** (a) Calcule el puntaje z de $x = 74$ si $\mu = 50$, $\sigma = 8$, y evalúe el criterio $|z| > 2,5$. (b) Indique qué valor toma $x = -4$ con MaxAbsScaler si el máximo valor absoluto de la característica es 10. (c) Explique cuál de estos métodos conviene si una variable tiene valores extremos y se desea centrarla alrededor de su mediana.

Resultado. (a) $z = 3$ y cumple $|z| > 2,5$. (b) MaxAbs = $-0,4$. (c) RobustScaler.

Cómo se obtiene. $z = (74 - 50)/8 = 3$; el umbral 2,5 es el criterio dado. MaxAbs divide por el máximo absoluto: $-4/10 = -0,4$. RobustScaler centra en la mediana y divide por el IQR, por lo que resiste mejor valores extremos; requiere $IQR > 0$. **T3. Chi-cuadrado con una tabla nueva.** Calcule todas las frecuencias esperadas y χ^2 para:

Color	Compra: sí	Compra: no	Total
Rojos	16	8	24
Azul	5	15	20
Verde	9	7	16
Total	30	30	60

Explique qué mide el estadístico y qué indica un valor cercano a cero.

Resultado. Esperados: Rojo (12, 12), Azul (10, 10), Verde (8, 8). $\chi^2 = 95/12 \approx 7,9167$.

Cómo se obtiene. Cada total de fila (24, 20, 16) se multiplica por cada total de columna (30) y se divide por 60. Los aportes $(O - E)^2/E$ por fila son 8/3, 5 y 1/4; suman 95/12. Un valor cercano a cero indicaría que lo observado se parece a lo esperado bajo independencia. **T4. Verdadero o falso;**

justifique cada respuesta. (a) CRISP-DM impide volver a Data Understanding después de evaluar. (b) Pearson cercano a cero descarta toda relación entre dos variables. (c) Lasso puede hacer exactamente cero algunos coeficientes. (d) One-Hot siempre produce menos columnas que la variable original. (e) Una característica rara con poca varianza nunca es útil. (f) El escalado de los datos puede alterar las distancias usadas por KNN.

Resultado. (a) Falso. (b) Falso. (c) Verdadero. (d) Falso. (e) Falso. (f) Verdadero.

Cómo se obtiene. (a) CRISP-DM permite volver a fases anteriores. (b) Pearson solo mide relación lineal. (c) Lasso puede anular pesos mediante L1. (d) One-Hot suele crear una columna por categoría. (e) Una característica rara puede ser predictiva. (f) Escalar cambia las distancias que utiliza KNN.

Formulario de referencia

Las fórmulas se aplican a una característica numérica X . En escalado, los parámetros se calculan con los datos de referencia y luego se aplican a los valores que se desean transformar. En un proyecto real, los parámetros de imputación, escalado, codificación y selección se ajustan con el conjunto de entrenamiento y después se aplican a validación o prueba para evitar fuga de información. En estos ejercicios, use únicamente los datos indicados en cada enunciado.

Media y desviación estándar (convención con divisor N).

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i.$$

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2}.$$

Rango intercuartílico.

$$IQR = Q_3 - Q_1.$$

Estandarización. El puntaje z indica cuántas desviaciones estándar separan x de la media μ : $z = 0$ en la media, $z > 0$ por encima y $z < 0$ por debajo.

$$z = \frac{x - \mu}{\sigma}.$$

Escalado Min-Max al intervalo $[0, 1]$. Reubica el mínimo observado en 0 y el máximo en 1; los valores intermedios conservan su posición relativa entre ambos extremos.

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}.$$

Escalado robusto.

$$x' = \frac{x - \text{mediana}(X)}{Q_3 - Q_1}.$$

Escalado MaxAbs.

$$x' = \frac{x}{\max_i |x_i|}.$$

Correlación lineal de Pearson. Su signo indica la dirección y su magnitud la fuerza de la asociación lineal. Un valor cercano a cero no descarta relaciones no lineales.

$$r_{XY} = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^N (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^N (y_i - \bar{y})^2}}.$$

Frecuencia esperada y estadístico chi-cuadrado. En una tabla de contingencia, O_{ij} es el conteo observado y E_{ij} es el conteo esperado si las variables fueran independientes. Cada celda aporta una discrepancia no negativa a χ^2 .

$$E_{ij} = \frac{(\text{total de fila } i)(\text{total de columna } j)}{N}.$$

$$\chi^2 = \sum_i \sum_j \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

Varianza explicada acumulada por las primeras k componentes de PCA. Los λ_j representan la varianza captada por cada componente. Si ya se entregan *proporciones* de varianza explicada, basta sumarlas en orden hasta alcanzar el porcentaje deseado.

$$V_k = \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^m \lambda_j}.$$